

Dati da internet e una regressione

L7 • Informatica per economisti • SIMA 2026

Oggi

1

Spiegazione e demo

25 min

Leggere dati dal web, la regressione con statsmodels

2

Task

60 min

CO₂ nel mondo, fatturato e addetti

3

Debrief

25 min

Gli aggregati nascosti e le osservazioni perse

Dati da internet: un indirizzo al posto del file

PYTHON

```
url = "https://raw.githubusercontent.com/owid/...csv"  
co2 = pd.read_csv(url)
```

- Molti enti pubblicano dati scaricabili: Our World in Data, Eurostat, ISTAT, Banca d'Italia, World Bank.
- Se il file è online, `read_csv` e `read_excel` accettano direttamente l'indirizzo.
- Il vantaggio: rilanci il notebook e hai i dati aggiornati.
- **Il rischio: i dati cambiano, e con loro i tuoi risultati. Annota quando li hai scaricati.**

Leggere la descrizione dei dati

PRIMA DI ANALIZZARE

Ogni dataset serio ha una descrizione delle colonne (codebook): unità di misura, fonte, cosa contiene davvero ogni riga.

LA DOMANDA CHIAVE

Cosa rappresenta una riga? Un paese in un anno?
O anche un continente, un gruppo di paesi, il mondo intero?

Le stesse domande della L2, su dati che non hai preparato tu.

Una regressione in una riga

PYTHON

```
import statsmodels.formula.api as smf
m = smf.ols("fatturato ~ addetti", data=df).fit()
print(m.summary())
```

"y ~ x": y in funzione di x

"y ~ x + z": più variabili

OLS: la retta che passa più vicino ai punti.

coefficiente

di quanto cambia y, in media, se x aumenta di 1

R²

quanta parte della variabilità di y è descritta

No. Observations

su quante righe è stata stimata

Associazione, non causa: la causalità è il mestiere dei vostri corsi di econometria.

Task: CO₂ e fatturato

Dati veri, una regressione, e qualche sorpresa.

60 minuti · apri il notebook dal README

Debrief

Quello che i dati non dicono da soli

Il mondo contato sei volte

240.370

somma di tutte le righe

milioni di t di CO₂, 2022

37.528

riga «World»

milioni di t di CO₂, 2022

La colonna country contiene anche continenti, UE, gruppi di reddito, il mondo.

Gli aggregati non hanno iso_code: filtrando restano 218 paesi.

Cosa rappresenta una riga? Prima domanda, sempre.

Leggere la regressione

140

coefficiente

migliaia di € per
addetto

0,73

R^2

2.375

osservazioni

non 2.500!

Le righe con un valore
mancante vengono escluse
in silenzio.

Aggiungendo la R&S:
coefficiente 116,
osservazioni 2.255.

Ogni volta che riporti una regressione, riporta anche su quante osservazioni.

Prossima volta: dal notebook allo script

Compito: scegliete domanda e dati per il mini-progetto