

Pulire i dati

L3 • Informatica per economisti • SIMA 2026

Oggi

1

Spiegazione e demo

25 min

Testo, conversioni, valori mancanti

2

Task

60 min

Pulire imprese.xlsx, un problema alla volta

3

Debrief

25 min

Le trappole silenziose e le nostre decisioni

Pulire è decidere



Nessuna correzione è automatica: ogni volta scegli tu. **Le decisioni vanno scritte.**

La regola: conta prima, conta dopo

PYTHON

```
print(df.shape)
df = df.drop_duplicates()
print(df.shape)
```

OUTPUT

```
(1000, 5)
(980, 5)
```

Quante righe dovevano sparire? 20? Allora va bene.

Molti errori di pulizia non danno messaggi: perdi dati in silenzio.

Contare è l'unica difesa.

Lavorare sul testo: .str

PYTHON

```
citta.str.strip()
```

OUTPUT

```
" Milano " → "Milano"
```

PYTHON

```
citta.str.strip().str.lower()
```

- Le colonne di testo hanno comandi dedicati, dopo .str
- strip, lower, upper, title, replace...
- Si possono mettere in fila, uno dopo l'altro
- **Quelli automatici non conoscono le eccezioni: controlla sempre**

Da testo a numero

PYTHON

```
pd.to_numeric(col, errors="coerce")
```

OUTPUT

"12.5"	→	12.5
"abc"	→	NaN
"12,5"	→	NaN

ATTENZIONE

Quello che non si converte diventa un valore mancante. Senza errori.

Dopo ogni conversione: conta i mancanti.

Correggere solo alcune righe

PYTHON

```
negativi = df["prezzo"] < 0  
print(negativi.sum())  
df.loc[negativi, "prezzo"] = None
```

- Una condizione è una colonna di True e False
- .sum() conta quante righe la rispettano
- .loc[righe, colonna] = valore

MANCANTE NON È ZERO

Media di 10, ?, 20

con il mancante: 15

con lo 0: 10

Task: pulisci il dataset

Obiettivo: 2.500 righe, 20 regioni, un fatturato numerico e plausibile.

60 minuti · apri il notebook dal README

Prossima volta: raggruppare e disegnare

Compito: Kaggle Learn – Pandas, «Data Types and Missing Values» (~20 min)